

Examen Final – Diseño e Implementación de un Sistema de Recuperación de Información

1. Instrucciones:

En este examen, los estudiantes deberán diseñar, implementar y evaluar un sistema completo de Recuperación de Información, utilizando la base de datos arXiv Paper Abstracts de Kaggle.

El objetivo es responder consultas relacionadas con la temática de los documentos del corpus mediante un enfoque moderno basado en embeddings y re-ranking, y analizar el desempeño del sistema utilizando métricas estándar de Recuperación de Información.

2. Base de datos

La base de datos utilizada en el examen corresponde a la colección **arXiv Paper Abstracts**, que está compuesta por títulos, abstracts y tópicos de papers científicos.

3. Objetivo del sistema

El sistema deberá implementar un Sistema de Recuperación Aumentada por Generación RAG capaz de responder consultas en lenguaje natural sobre un corpus de resúmenes de artículos científicos del corpus.

El usuario podrá realizar consultas como, por ejemplo:

- *"What are the main applications of Graph Neural Networks?"*
- *"How is reinforcement learning used in robotics?"*
- *"Recent advances in diffusion models for image generation."*
- *"Techniques for improving retrieval-augmented generation systems."*

Para cada consulta, el sistema deberá:

1. Recuperar los documentos más relevantes del corpus mediante búsqueda semántica sobre una base de datos vectorial.
2. Utilizar dichos fragmentos como contexto para generar una respuesta mediante un Modelo de Lenguaje Grande (LLM).
3. Mostrar al usuario las evidencias utilizadas para construir la respuesta, incluyendo los documentos y fragmentos recuperados.
4. Indicar explícitamente cuando el corpus no contenga información suficiente para responder la consulta.

El sistema deberá ofrecer una interfaz web tipo chat, accesible mediante un navegador, que permita interactuar con el sistema RAG de forma similar a un asistente conversacional. La aplicación deberá estar desplegada en un servicio en la nube y permanecer disponible durante el período de evaluación del proyecto.

4. Requerimientos

- A. Preparación del corpus
- B. Representación mediante embeddings
- C. Almacenamiento y búsqueda vectorial
- D. Recuperación
- E. Generación aumentada por recuperación
- F. Presentación de evidencias

- El sistema deberá mostrar las evidencias utilizadas para generar cada respuesta.
- Las evidencias deberán permitir verificar la relación entre la consulta, los documentos recuperados y la respuesta generada por el LLM.

G. Interfaz web conversacional

- Desarrollo de una interfaz web tipo chat que permita:
 - ingresar consultas en lenguaje natural;
 - visualizar la respuesta generada y evidencias utilizadas;
 - realizar nuevas consultas sin reiniciar manualmente la aplicación.
- No será obligatorio implementar memoria conversacional. Cada consulta podrá procesarse de manera independiente.
- La calidad gráfica no será el principal criterio de evaluación, pero la aplicación deberá ser comprensible y fácil de utilizar.

H. Despliegue en la nube

- La aplicación deberá estar desplegada en un servicio en la nube y ser accesible mediante una URL.
- Se podrá utilizar Hugging Face Spaces, Streamlit Community Cloud, Render, Railway, Google Cloud Run, AWS, Azure u otra plataforma equivalente.
- La URL deberá:
 - ser accesible desde un navegador;
 - permitir interactuar con el sistema sin instalar dependencias;
 - permanecer activa durante el período de evaluación;
 - permitir que el docente realice consultas diferentes de las utilizadas por el grupo durante el desarrollo.
 - Las claves de API no deberán almacenarse directamente en el código fuente ni publicarse en el repositorio. Se deberán utilizar variables de entorno o mecanismos de gestión de secretos.

I. Evaluación del sistema y de la generación

Se deberá documentar un juicio subjetivo sobre:

- Corrección de la respuesta.
- Relevancia con respecto a la consulta.
- Fidelidad respecto de las evidencias recuperadas.
- Capacidad para integrar información de varios documentos.
- Capacidad para reconocer cuando el corpus no contiene información suficiente.

4. Formato de Entrega

- **Jupyter Notebook**

El notebook debe incluir al menos un bloque de Markdown y uno de código para cada uno de los ítems señalados en **Requerimientos**.

- **URL**

En el Notebook se deberá presentar el link a la URL donde se tenga desplegado el chat RAG.